

دانشگاه شهید بهشتی

دانشکده مهندسی و علوم کامپیوتر – گرایش هوش مصنوعی

گزارش کامل پروژه کارشناسی

بهینه‌سازی مصرف انرژی در شبکه‌های اینترنت اشیا با یادگیری تقویتی عمیق

IoT Energy Optimization using Deep Reinforcement Learning (DQN)

از بیان مسئله تا معماری، آموزش عامل، نتایج و آمادگی ارائه

دانشجو	امیرمحمد ذکاوتی اول
استاد راهنما	دکتر منیره عبدوس
سال تحصیلی	۱۴۰۴ – ۱۴۰۵
نوع سند	گزارش کامل فنی پژوهشی برای دفاع شفاهی
نتایج رسمی آزمایش	۳ گره، افق ۵۰ گام، آموزش ۶۰۰۰ گام، میانگین ۵ اپیزود، بذر ۴۲

این گزارش تمام بخش‌های پیاده‌سازی، فرمول‌ها، معیارها، محدودیت‌ها و پرسش‌های محتمل اساتید را پوشش می‌دهد.

این پروژه یک سامانه نرم‌افزاری کامل برای بهینه‌سازی مصرف انرژی در شبکه‌های حسگر اینترنت اشیا (**Internet of Things** یا **IoT**) می‌سازد. مسئله اصلی این است که هر گره باتری‌محدود، در هر گام زمانی، باید بین دو عمل انتخاب کند: ارسال (**transmit**) یا خواب (**sleep**). ارسال داده را تازه نگه می‌دارد اما انرژی رادیویی زیادی مصرف می‌کند؛ خواب انرژی را حفظ می‌کند اما اگر زیاد تکرار شود، شبکه عملاً هیچ سرویسی به دروازه نمی‌دهد.

برای حل این مصالحه، یک شبیه‌ساز گسسته‌زمان ساخته شد که گره، بسته، دروازه، مدل انرژی فاصله‌آگاه، کانال با احتمال افت بسته، و سن اطلاعات (**Age of Information** یا **Aoi**) را در بر دارد. سپس همین شبیه‌ساز داخل محیط استاندارد **Gymnasium** قرار گرفت تا عامل شبکه عمیق کیو (**Deep Q-Network** یا **DQN**) با کتابخانه **Stable-Baselines3** آموزش ببیند. سیاست یادگرفته‌شده با سه خط‌پایه مقایسه می‌شود: ارسال دائمی، خواب دائمی، و انتخاب تصادفی. داشبورد **Streamlit** امکان تنظیم پارامتر، آموزش، اجرا و مقایسه را فراهم می‌کند.

در آزمایش رسمی با ۳ گره، افق ۵۰ گام و ۶۰۰۰ گام آموزش، عامل **DQN** به طول عمر میانگین ۴۹/۴ گام، ۲۹/۴ بسته موفق، نسبت تحویل بسته حدود ۰/۷۶ و میانگین **Aoi** برابر ۱۶/۲ رسید. این نتیجه نشان می‌دهد سیاست یادگرفته‌شده می‌تواند عمری نزدیک خواب دائمی بسازد، در حالی که سرویس داده را قربانی نمی‌کند و حتی از ارسال دائمی بسته موفق بیشتری به دروازه می‌رساند.

کلیدواژه‌ها: اینترنت اشیا، شبکه حسگر بی‌سیم، بهینه‌سازی انرژی، سن اطلاعات، یادگیری تقویتی عمیق، **DQN**، **Gymnasium**، شبیه‌سازی.

فهرست مطالب


فصل ۱	مقدمه، اهمیت مسئله و اهداف پروژه
فصل ۲	مبانی نظری: انرژی، سن اطلاعات و یادگیری تقویتی
فصل ۳	مروری بر کارهای مرتبط و جایگاه این پروژه
فصل ۴	معماری سامانه و ساختار پوشه‌ها
فصل ۵	شبیه‌ساز شبکه: گره، بسته، دروازه و زمان‌بند
فصل ۶	مدل انرژی، کانال بی‌سیم و به‌روزرسانی سن اطلاعات
فصل ۷	صورت‌بندی MDP : مشاهده، عمل و پاداش
فصل ۸	عامل DQN ، ابرپارامترها و حلقه آموزش
فصل ۹	معیارهای ارزیابی، خط‌پایه‌ها و مقایسه سیاست‌ها
فصل ۱۰	داشبورد، نوت‌بوک‌ها و آزمون دود
فصل ۱۱	نتایج آزمایش رسمی و تفسیر نمودارها
فصل ۱۲	محدودیت‌ها، کارهای آینده و جمع‌بندی
پیوست	واژه‌نامه، جدول پارامترها، راهنمای اجرا و منابع

برای ارائه شفاهی: هر فصل را تا بخش «پرسش‌های محتمل» بخوانید. همان پرسش‌ها معمولاً در جلسه دفاع تکرار می‌شوند.

فصل ۱. مقدمه، اهمیت مسئله و اهداف پروژه

۱-۱ زمینه و انگیزه

اینترنت اشیا شبکه‌ای از دستگاه‌های متصل است که محیط را حس می‌کنند، داده می‌سازند و آن را به یک نقطه جمع‌آوری (دروازه یا **gateway**) می‌فرستند. طبق گزارش **Transforma Insights**، تعداد اتصالات جهانی **IoT** از حدود ۲۱ میلیارد در سال ۲۰۲۵ به حدود ۴۸ میلیارد در سال ۲۰۳۵ می‌رسد [1]. بخش بزرگی از این دستگاه‌ها با باتری کار می‌کنند و تعویض یا شارژ باتری در مزرعه، کارخانه، جنگل یا زیرساخت شهری گران، سخت یا حتی غیرممکن است. در شبکه حسگر بی‌سیم (**Wireless Sensor Network** یا **WSN**) پرهزینه‌ترین کار معمولاً ارسال رادیویی است، نه محاسبات محلی [3]. اگر گره‌ها همیشه ارسال کنند، باتری زود تمام می‌شود و شبکه می‌میرد. اگر همیشه بخواهند، انرژی می‌ماند ولی هیچ داده‌ای به مقصد نمی‌رسد. بنابراین مسئله اصلی **تصمیم تطبیقی** است: چه زمانی ارسال کنیم و چه زمانی انرژی را نگه داریم.



شکل ۱-۱. اکوسیستم اینترنت اشیا. تمرکز این پروژه لایه اول است: گره حسگر تا دروازه، نه لایه ابر.


۱-۲ بیان مسئله

فرض کنید شبکه‌ای با n گره حسگر در یک مربع ۱۰۰ در ۱۰۰ متر قرار دارد و دروازه در مرکز است. زمان به گام‌های گسسته تقسیم شده است. در هر گام، برای هر گره زنده یکی از دو عمل انتخاب می‌شود:

- **ارسال:** گره بیدار می‌شود، محیط را حس می‌کند، بسته می‌سازد، انرژی ارسال می‌پردازد و بسته را روی کانال می‌گذارد. کانال ممکن است بسته را به دروازه برساند یا آن را بیندازد.
- **خواب:** گره به حالت کم‌مصرف می‌رود و فقط هزینه ناچیز خواب را می‌پردازد. در این گام هیچ بسته‌ای ساخته نمی‌شود.

سه ضلع مسئله هم‌زمان باید دیده شوند:

1. مصرف انرژی و عمر شبکه
2. تازگی اطلاعات در مقصد (Aol)
3. اتلاف بسته روی کانال




شکل ۱-۲. مسئله سه‌ضلعی: انرژی، کهنگی اطلاعات، و اتلاف بسته.

سیاست خوب الزاماً سیاستی نیست که بیشترین بسته را بفرستد. سیاست خوب سیاستی است که با انرژی محدود، سرویس پایدار و اطلاعات نسبتاً تازه بسازد.

۱-۳ چرا یادگیری تقویتی؟

روش‌های سنتی مثل آستانه‌گذاری دستی یا پروتکل‌های قاعده‌محور (نمونه کلاسیک: **LEACH** [4]) برای یک سناریوی ثابت خوب کار می‌کنند، اما اگر فاصله گره‌ها، احتمال افت، و وضعیت باتری عوض شود، قاعده ثابت کم می‌آورد [5]. یادگیری تقویتی (**Reinforcement Learning** یا **RL**) دقیقاً برای همین فضا طراحی شده است: عامل وضعیت را می‌بیند، عمل می‌کند، پاداش می‌گیرد و سیاست را بهبود می‌دهد؛ بدون اینکه برچسب صحیح از قبل موجود باشد [2].

در این پروژه از **DQN** استفاده شده چون فضای عمل گسسته و دودویی است (ارسال یا خواب برای هر گره). **DQN** تابع ارزش عمل را با شبکه عصبی تقریب می‌زند و برای عمل گسسته انتخاب استاندارد ادبیات است.



شکل ۱-۳. چهار شاخه کار: شبیه‌سازی، مدل انرژی، یادگیری تقویتی عمیق، و ارزیابی مقایسه‌ای.

1. ساخت شبیه‌ساز قابل تکرار شامل گره، بسته، دروازه، انرژی فاصله‌آگاه، افت بسته و **Aol**.
2. پوشاندن شبیه‌ساز با محیط **Gymnasium** و تعریف مشاهده، عمل و پاداش چندهدفه.
3. آموزش عامل **DQN** با **Stable-Baselines3** و ذخیره مدل.
4. مقایسه عادلانه با سه خط‌پایه: ارسال دائمی، خواب دائمی، تصادفی.
5. داشبورد تعاملی برای نمایش زنده در جلسه ارائه.
6. آزمون دود خودکار تا حلقه شبیه‌ساز تا آموزش کوتاه نشکند.

۵-۱ محدوده و آنچه عمداً انجام نشده

محدوده پروژه باید شفاف گفته شود؛ این ضعف نیست، مرز علمی کار است:

- کار کاملاً شبیه‌سازی نرم‌افزاری است؛ سخت‌افزار واقعی مثل **ESP32** در حلقه نیست.
- ارتباط تک‌گام (**single-hop**) به یک دروازه مرکزی است؛ مسیریابی چندگامه و خوشه‌بندی وجود ندارد.
- سقف ۱۰ گره برای سازگاری با فضای عمل گسسته **DQN** گذاشته شده است.

- داده حسگر مصنوعی است و محتوای معنایی ندارد.
- مدل کانال و انرژی آموزشی و فاصله محور است، نه مدل لایه فیزیکی کامل (path loss)، تداخل چندکاربره، MAC پیچیده).
- صف بسته جداگانه در کد فعلی وجود ندارد؛ تصمیم هر گام فوری اعمال می‌شود.

۱-۶ پرسش‌های محتمل این فصل

پرسش: مسئله شما به یک جمله چیست؟

پاسخ: هر گره حسگر با باتری محدود باید در هر گام بین ارسال و خواب یکی را انتخاب کند تا هم عمر شبکه بماند هم داده نسبتاً تازه به دروازه برسد.

پرسش: چرا انرژی در اینترنت اشیا این قدر مهم است؟

پاسخ: چون تعداد دستگاه‌ها بسیار زیاد است، بسیاری باتری محدودند، و ارسال رادیویی معمولاً پرهزینه‌ترین بخش انرژی است. تعویض باتری در مقیاس بزرگ عملی نیست.

پرسش: تفاوت کار شما با بهینه‌سازی انرژی در موبایل یا مراکز داده چیست؟

پاسخ: اینجا گره بسیار کم‌توان است، ارتباط بی‌سیم نامطمئن است، و معیار تازگی اطلاعات در مقصد هم مهم است. مسئله حسگر تا دروازه است، نه مدیریت سرور.

پرسش: اگر کار شبیه‌سازی است، ارزش پژوهشی آن چیست؟

پاسخ: ارزش در صورت‌بندی مسئله، تعریف مشاهده و پاداش، ساخت حلقه ارزیابی تکرارپذیر، و نشان دادن مصالحه سیاست‌هاست. شبیه‌سازی کنترل‌شده پیش‌نیاز آزمایش سخت‌افزار است.

پرسش: چرا سقف ۱۰ گره؟

پاسخ: برای n گره، فضای عمل فشرده ۲ به توان n است. با ۱۰ گره ۱۰۲۴ عمل داریم که هنوز برای DQN قابل مدیریت است. بزرگ‌تر از آن انفجار ترکیبی رخ می‌دهد.

پرسش: نوآوری شما الگوریتم جدید است یا سامانه؟

پاسخ: الگوریتم DQN از ادبیات است. سهم این پروژه صورت‌بندی مسئله خواب/ارسال تک‌گام، شبیه‌ساز فاصله‌آگاه با افت و Aol، اتصال به عامل، مقایسه سه خط‌پایه، و ابزار نمایش است.

پرسش: اگر استاد بگوید کار ساده است چه می‌گویید؟

پاسخ: سادگی عمدی است. مقالات سنگین روی مسیریابی و نظریه بازی تمرکز دارند. شکاف این پروژه یک سامانه سبک، قابل توضیح و قابل نمایش برای تصمیم خواب/ارسال است.

فصل ۲. مبانی نظری

۲-۱ شبکه حسگر بی سیم و اینترنت اشیا

شبکه حسگر بی سیم مجموعه‌ای از گره‌های کم‌هزینه است که پدیده فیزیکی را می‌سنجند و داده را به چاهک (sink) یا دروازه می‌فرستند. اینترنت اشیا این ایده را به مقیاس بزرگ‌تر و کاربردهای متنوع‌تر می‌برد: پایش محیط، کشاورزی هوشمند، شهر هوشمند، سلامت، و صنعت. در همه این‌ها یک فرض مشترک وجود دارد: انرژی کمیاب است و ارتباط بی سیم قابل اعتماد کامل نیست [2][3].

توپولوژی این پروژه ستاره‌ای (star) است: همه گره‌ها مستقیم به یک دروازه متصل می‌شوند. این توپولوژی برای محیط آموزشی شفاف است، چون اثر تصمیم خواب/ارسال با اثر مسیریابی چندگانه قاطی نمی‌شود.

۲-۲ مدل انرژی

چهار نوع هزینه در پروژه تعریف شده است (واحد ژول در هر گام یا هر رویداد):

- حس کردن: ۰/۰۱
 - ارسال پایه: ۰/۰۵ که با فاصله افزایش می‌یابد
 - خواب: ۰/۰۰۱
 - دریافت: ۰/۰۲ (در مدل گره موجود است؛ در مسیر فعلی حسگر به دروازه، دروازه انرژی مصرف نمی‌کند)
- هزینه ارسال فاصله‌آگاه از ایده مدل‌های کلاسیک انرژی رادیویی الهام گرفته، اما ساده‌سازی آموزشی دارد:

$$E_{tx}(d) = E_{TX} \cdot [1 + w \cdot (d / d_{ref})^2]$$

هزینه ارسال به صورت تابعی از فاصله اقلیدسی تا دروازه

با مقادیر پیش فرض $E_{TX} = 0.05$ ، $w = 0.5$ و $d_{ref} = 50$ متر:

$$E_{tx}(d) = 0.05 \cdot [1 + 0.5 \cdot (d / 50)^2]$$

اگر گره کنار دروازه باشد، هزینه نزدیک ۰/۰۵ ژول است. اگر فاصله برابر فاصله مرجع باشد، ضریب ۱/۵ می‌شود و هزینه ۰/۰۷۵ ژول است. نکته حیاتی: انرژی تلاش ارسال حتی اگر بسته روی کانال بیفتد هم کم می‌شود. این یعنی ارسال بی فکر هم باتری را می‌سوزاند هم ممکن است داده نرسد.

۲-۳ کانال و احتمال تحویل

احتمال تحویل با فاصله به صورت خطی کاهش می یابد و سپس در بازه مجاز بریده می شود:

$$p(d) = \text{clip}(1 - \lambda \cdot (d / d_{\text{ref}}), p_{\text{min}}, 1)$$

λ ضریب افت و p_{min} کف احتمال تحویل است

با $\lambda = 0.35$ و $p_{\text{min}} = 0.45$:

$$p(d) = \text{clip}(1 - 0.35 \cdot (d / 50), 0.45, 1)$$

نزدیک دروازه تقریباً همیشه تحویل موفق است. با دور شدن، افت بیشتر می شود ولی هرگز از ۴۵ درصد پایین تر نمی آید تا شبکه دوردست کاملاً کور نشود. این مدل **i.i.d.** است: هر تلاش ارسال مستقل از قبلی نمونه گیری می شود.

۲-۴ سن اطلاعات

سن اطلاعات (**Aol**) می گوید اطلاعات مقصد چقدر کهنه است؛ از لحظه آخرین به روزرسانی موفق شمرده می شود. با تأخیر یک بسته در راه فرق دارد: حتی اگر هیچ بسته ای در پرواز نباشد، **Aol** باز هم با گذر زمان پیر می شود.

$$A_i(t+1) = 1 \quad \text{تحویل شود } t \text{ در گام } i \text{ اگر بسته گره}$$

$$A_i(t+1) = A_i(t) + 1 \quad \text{در غیر این صورت}$$

میانگین شبکه فقط روی گره های زنده حساب می شود. در پیاده سازی، پس از تحویل موفق مقدار به ۱ می رود نه صفر؛ یعنی حداقل سن پس از یک به روزرسانی یک گام است. این قرارداد پیاده سازی را در ارائه صریح بگویید.

۲-۵ یادگیری تقویتی و فرآیند تصمیم مارکوف

یادگیری تقویتی تعامل عامل و محیط را در قالب فرآیند تصمیم مارکوف (**Markov Decision Process** یا **MDP**) می بیند: چندتایی

$$(S, A, P, R, \gamma)$$

S فضای وضعیت، **A** فضای عمل، **P** گذار، **R** پاداش، و γ ضریب تخفیف است. هدف بیشینه کردن امید مجموع پاداش تخفیف خورده است:

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

سیاست $\pi(a|s)$ احتمال انتخاب عمل در هر وضعیت است. تابع ارزش عمل می گوید اگر در وضعیت **s** عمل **a** را بگیریم و بعد بهینه ادامه دهیم، چقدر پاداش انتظاری داریم:

$$Q^{\pi}(s,a) = E[G_t \mid s_t=s, a_t=a]$$

۲-۶ شبکه عمیق کیو

در فضای بزرگ، جدول **Q** قابل ذخیره نیست. **DQN** این تابع را با شبکه عصبی $Q(s,a; \theta)$ تقریب می زند. معادله به روزرسانی ایده آل همان رابطه بلمن است:

$$Q(s,a) \approx r + \gamma \max_{a'} Q(s', a')$$

دو ترفند پایداری که در پیاده سازی **Stable-Baselines3** هم هست:

1. حافظه بازپخش تجربه (**experience replay**): گذارها در بافر ذخیره می شوند و دسته ای تصادفی برای آموزش کشیده می شود تا همبستگی زمانی بشکند.
 2. شبکه هدف (**target network**): مقدار هدف از یک کپی کندبه روز از شبکه می آید تا هدف آموزشی هر چند گام یک بار نپرد.
- اکتشاف با **ϵ -greedy** انجام می شود: با احتمال ϵ عمل تصادفی، وگرنه عمل با بیشترین **Q**. ϵ در طول آموزش از مقدار بزرگ به ۰/۰۵ کاهش می یابد.

۲-۷ پرسش های محتمل این فصل

پرسش: تفاوت Aol با تأخیر بسته چیست؟

پاسخ: تأخیر مدت سفر یک بسته مشخص است. Aol سن اطلاعات موجود در مقصد است و حتی بدون بسته در راه هم با زمان زیاد می شود. اگر مدتی هیچ به روزرسانی نرسد، Aol بالا می رود.

پرسش: چرا هزینه ارسال را با مربع فاصله زیاد کردید؟

پاسخ: در مدل‌های رادیویی ساده، انرژی برای غلبه بر افت مسیر با فاصله رشد می‌کند. مربع فاصله یک تقریب آموزشی شفاف است، نه مدل کانال دقیق شهری.

پرسش: چرا کف احتمال تحویل ۴۵ درصد است؟

پاسخ: تا گره دور کاملاً ناامید نشود و مسئله به «فقط گره‌های نزدیک مفیدند» فرو نیفتد. این یک ابرپارامتر طراحی است و ادعای فیزیکی دقیق ندارد.

پرسش: MDP بودن مسئله را چطور توجیه می‌کنید؟

پاسخ: تقریباً مارکوف است: انرژی، حیات، گام، نسبت دریافت و AOI در مشاهده آمده‌اند. مختصات گره مستقیم در مشاهده نیست؛ اثرش از راه انرژی و افت دیده می‌شود. این تقریب است نه اثبات کامل مارکوف.

پرسش: چرا DQN نه جدول Q-learning؟

پاسخ: مشاهده پیوسته است (نسبت انرژی و زمان). جدول گسسته این فضا را خوب پوشش نمی‌دهد. شبکه عصبی تعمیم بین وضعیت‌های شبیه را ممکن می‌کند.

پرسش: ضریب تخفیف $\gamma=0.95$ یعنی چه؟

پاسخ: عامل به پاداش آینده اهمیت می‌دهد، اما کمی کمتر از پاداش فعلی. اگر γ خیلی نزدیک ۱ باشد، افق خیلی دور می‌شود و یادگیری سخت‌تر است؛ اگر خیلی کوچک باشد، عامل نزدیک‌بین می‌شود و عمر شبکه را فدا می‌کند.

پرسش: تجربه بازپخش دقیقاً چه مشکلی را حل می‌کند؟

پاسخ: نمونه‌های پشت‌سرهم در یک اپیزود همبسته‌اند. اگر همان ترتیب را به شبکه بدهیم، برآورد گرادینت پرنویز و بی‌ثبات می‌شود. نمونه‌گیری تصادفی از بافر این همبستگی را کم می‌کند.

فصل ۳. مروری بر کارهای مرتبط

هدف این فصل اثبات این نیست که کار حاضر از همه مقالات ۲۰۲۵ قوی‌تر است. هدف این است که نشان دهیم مسئله انرژی در شبکه حسگر ریشه‌دار است، روش‌های سنتی و هوشمند هر دو وجود دارند، و جایگاه این پروژه یک سامانه سبک برای تصمیم خواب/ارسال است نه تکرار مسیریابی پیچیده.

۳-۱ مدیریت انرژی سنتی

پروتکل **LEACH** [4] نماینده کلاسیک روش قاعده‌محور است: شبکه خوشه‌بندی می‌شود و نقش سرخوشه می‌چرخد تا مصرف انرژی بین گره‌ها پخش شود. ایده بسیار تأثیرگذار بوده، اما تصمیم‌ها از قاعده احتمالی می‌آیند نه از یادگیری وضعیت فعلی باتری، کانال و تازگی داده. مرورهای بعدی نشان می‌دهند انرژی همچنان گلوگاه اصلی **WSN** است و مسیریابی انرژی کارآمد یک خط پژوهشی طولانی دارد [3].

کار **Kaur** و **Chanak** [5] تأکید می‌کند روش‌های سنتی در شرایط پویا کم می‌آورند و به طرح هوشمند نیاز است. این جمله مجوز ورود یادگیری ماشین به مسئله انرژی است.

۳-۲ یادگیری ماشین و یادگیری تقویتی در شبکه حسگر

مقاله مروری **Alsheikh** و همکاران [2] نشان می‌دهد یادگیری ماشین از سال‌ها پیش برای خوشه‌بندی، آشکارسازی رویداد و مدیریت منابع در **WSN** مطرح بوده است. **Meng** و همکاران [6] از یادگیری تقویتی عمیق برای بهینه‌سازی توپولوژی شبکه‌های خودسازمان‌ده استفاده کردند؛ مسئله‌شان توپولوژی است نه تصمیم دودویی خواب/ارسال. **Leong** و همکاران [9] زمان‌بندی حسگر در سامانه سایبر-فیزیکی را با یادگیری تقویتی عمیق حل کردند و نشان دادند زمان‌بندی حسگر یک مسئله شناخته‌شده است.

مقاله کلیدی مسیریابی: [7] EDRP-GTDQN

لیو و همکاران مسیریابی انرژی و تأخیر را با ترکیب نظریه بازی، شبکه پیچشی گراف و DQN حل می‌کنند. ابتدا سرخوشه با بازی انتخاب می‌شود، سپس مسیر با DQN چیده می‌شود. نسبت به LEACH و DEEC بهبود گزارش کرده‌اند.

تفاوت: آن‌ها مسیریابی و خوشه‌بندی پیچیده دارند. این پروژه مدیریت مستقیم خواب/ارسال در توپولوژی ستاره‌ای ساده است. مدل آن‌ها برای محیط آموزشی سبک مناسب نیست.

نزدیک‌ترین ایده خواب: [8] NashDQNSleep

بانرجی و همکاران زمان‌بندی خواب در اینترنت اشیا صنعتی را با DQN و تعادل نش برای انرژی و Aol پیشنهاد می‌کنند. تصمیم توزیع‌شده و هماهنگی بین گره‌ها در محیط صنعتی است.

تفاوت: ایده مشترک DQN برای خواب و توجه به Aol است. تفاوت در عامل مرکزی، شبکه ساده آموزشی، حلقه کامل شبیه‌ساز تا داشبورد، و مقایسه شفاف با سه خطاپایه است.

کار	تمرکز	ابزار	نسبت به این پروژه
LEACH [4]	خوشه‌بندی و چرخش سرخوشه	قاعده احتمالی	خطاپایه ادبیاتی؛ در کد پیاده نشده
Meng [6]	توپولوژی خودسازمان‌ده	DRL	مسئله متفاوت
EDRP-GTDQN [7]	مسیریابی و تأخیر	بازی + GCN + DQN	سنگین‌تر؛ خواب ساده ندارد
NashDQNSleep [8]	خواب و Aol صنعتی	DQN + Nash	نزدیک‌ترین ایده؛ مدل پیچیده‌تر
Leong [9]	زمان‌بندی حسگر	DRL	دامنه سایبر-فیزیکی متفاوت
پروژه حاضر	خواب/ارسال تک‌گام	DQN + شبیه‌ساز + داشبورد	سبک، قابل توضیح، قابل نمایش

۳-۴ شکاف پژوهشی که پروژه پر می‌کند

در ادبیات، کارهای قوی معمولاً یکی از این سه هستند: مسیریابی پیچیده، بازی چندعاملی صنعتی، یا زمان‌بندی حسگر در سامانه سایبر-فیزیکی. کمتر کاری هم‌زمان این حلقه را برای محیط آموزشی می‌بندد:

- شبیه‌ساز فاصله‌آگاه با افت بسته و Aol

- صورت‌بندی شفاف مشاهده و پاداش

- آموزش **DQN** آماده اجرا

- سه خط‌پایه قابل تفسیر

- داشبورد برای ارائه زنده

ادعای پروژه این نیست که **EDRP-GTDQN** را روی بنچمارک آن مقاله شکست داده است. ادعای پروژه این است که برای تصمیم خواب/ارسال تک‌گام، یک سامانه کامل، قابل دفاع و قابل نمایش ساخته شده است.

۵-۳ پرسش‌های محتمل این فصل

پرسش: چرا LEACH را پیاده نکردید؟

پاسخ: LEACH خوشه‌بندی چندگامه است و مسئله‌اش با خواب/ارسال تک‌گام یکی نیست. به‌عنوان نماینده روش سنتی در ادبیات آمده، نه به‌عنوان رقیب کدی. رقیب کدی سه خط‌پایه ساده و تفسیرپذیر است.

پرسش: پس شما مقاله ۲۰۲۵ را تکرار نکردید؟

پاسخ: درست است. تکرار EDRP-GTDQN یا NashDQNSleep یک پروژه جدا و سنگین‌تر است. سهم ما سامانه آموزشی‌پژوهشی برای تصمیم دودویی با حلقه ارزیابی کامل است.

پرسش: نزدیک‌ترین کار به شما کدام است؟

پاسخ: NashDQNSleep از نظر ایده خواب و AOL. تفاوت ما عامل مرکزی، توپولوژی ستاره، و ابزار نمایش است نه تعادل نش توزیع‌شده.

پرسش: آمار Transforma Insights چه نقشی دارد؟

پاسخ: فقط انگیزه مقدمه است. ورودی شبیه‌ساز نیست و روی نتایج آزمایش اثر ندارد.

پرسش: اگر بگویند مقایسه شما با مقالات کافی نیست؟

پاسخ: مقایسه کمی با مقالات روی یک بنچمارک مشترک انجام نشده چون مسئله و توپولوژی یکی نیست. مقایسه کیفی در جدول فصل ۳ آمده و مقایسه کمی با خط‌پایه‌های خود مسئله انجام شده که برای این صورت‌بندی درست‌تر است.

پرسش: یادگیری تقویتی در WSN جدید است؟

پاسخ: خیر. از سال‌ها پیش مطرح بوده. جدید بودن کار در بسته‌بندی مسئله خواب/ارسال با Aol، کانال فاصله‌آگاه و ابزار ارائه است.

فصل ۴. معماری سامانه و ساختار پوشه‌ها

۴-۱ نگاه کلی


سامانه چهار لایه دارد که همگی داخل یک پروژه پایتون ۳/۱۲ و بدون پایگاه داده یا سرویس جدا اجرا می‌شوند:

۱. رابط کاربری: داشبورد **Streamlit** در **app/ui/**


۲. شبیه‌سازی: گره، بسته، کانال، انرژی، دروازه، زمان‌بند در **app/simulation/**

۳. یادگیری: محیط، پاداش، عامل، مربی در **app/rl/**

۴. تحلیل: معیار، مقایسه، نمودار در **app/analytics/**



شکل ۴-۱. معماری چهارلایه سامانه.



شکل ۴-۲. جریان روش: تنظیم پارامتر، شبیه‌سازی، تصمیم‌گیری عامل، تاریخچه، معیار، مقایسه سیاست‌ها.


۴-۲ نقطه ورود و تنظیمات مرکزی

فایل **main.py** فقط داشبورد را صدا می‌زند. تمام اعداد مهم در کلاس **Settings** داخل فایل **app/config/settings.py** جمع شده‌اند تا آزمایش‌ها از یک منبع تغذیه شوند. پیش‌فرض کد ۱۰ گره و ۲۰۰ گام

است؛ آزمایش رسمی گزارش ۳ گره و ۵۰ گام است. این دو را قاطی نکنید.

گروه	پارامتر	پیش فرض کد	نقش
شبکه	NUM_NODES	10	تعداد گره‌ها
شبکه	AREA_SIZE	100 m	ضلع مربع شبیه‌سازی
شبکه	موقعیت دروازه	(50, 50)	مرکز ناحیه
انرژی	INITIAL_ENERGY	1.0 J	باتری اولیه هر گره
انرژی	TX_ENERGY	0.05 J	هزینه پایه ارسال
انرژی	SENSE_ENERGY	0.01 J	هزینه حس کردن
انرژی	SLEEP_ENERGY	0.001 J	هزینه یک گام خواب
زمان	MAX_STEPS	200	افق اپیزود
تکرارپذیری	RANDOM_SEED	42	بذر مکان گره‌ها و کانال
یادگیری	LEARNING_RATE	0.001	نرخ یادگیری DQN
یادگیری	GAMMA	0.95	تخفیف پاداش آینده
یادگیری	TRAIN_TIMESTEPS	10000	بودجه آموزش پیش فرض

مسئولیت	مسیر
دنیای فیزیکی ساده شده: مکان، انرژی، بسته، کانال، گام زمان	app/simulation/
ترجمه دنیا به MDP و آموزش سیاست	app/rl/
معیار، میانگین اپیزودها، نمودار مقایسه	app/analytics/
کنترل‌ها، نقشه شبکه، نمودارهای زنده	app/ui/
شش آزمایش گام به گام آموزشی	notebooks/
آزمون انتها به انتها با شبکه کوچک	tests/test_smoke.py
مدل ذخیره شده (در گیت نادیده گرفته می‌شود)	experiments/models/



شکل ۴-۳. جریان فرآیند از تنظیمات تا خروجی تحلیلی.

۴-۴ فناوری‌ها و دلیل انتخاب

- **Python 3.12**: زبان اصلی پروژه دانشگاهی و اکوسیستم یادگیری ماشین.
- **Pandas / NumPy**: بردار مشاهده و جدول معیارها.

- **Gymnasium**: قرارداد استاندارد **reset/step** برای اتصال به الگوریتم‌های آماده.
 - **PyTorch + Stable-Baselines3**: پیاده‌سازی آزموده **DQN** به‌جای بازنویسی از صفر.
 - **Streamlit**: داشبورد سریع بدون جدا کردن فرانت‌اند و بک‌اند.
 - **Altair / Matplotlib**: نمودار مقایسه و نقشه شبکه.
- هیچ پایگاه‌داده‌ای وجود ندارد. تاریخچه هر اجرا در حافظه به‌صورت لیست تصویرهای لحظه‌ای نگه داشته می‌شود. مدل آموزش‌دیده به صورت فایل **zip** در **experiments/models/** ذخیره می‌شود.

۴-۵ پرسش‌های محتمل این فصل

پرسش: چرا از میکروسرویس یا دیتابیس استفاده نکردید؟

پاسخ: مسئله پژوهشی به ذخیره ابری نیاز ندارد. شبیه‌ساز، مربی و تحلیل همگی درون‌فرآیندی هستند تا تکرار آزمایش ساده بماند.

پرسش: چرا Stable-Baselines3 و نه پیاده‌سازی دستی DQN؟

پاسخ: ارزش کار در صورت‌بندی مسئله IoT است نه بازنویسی گرادیان. استفاده از کتابخانه استاندارد در پژوهش کاربردی رایج و قابل دفاع است؛ ابرپارامترها و محیط اختصاصی‌اند.

پرسش: اگر تنظیمات داشبورد با تنظیمات آموزش فرق کند چه می‌شود؟

پاسخ: عامل نسبت به تعداد گره و ابعاد مشاهده حساس است. اگر با ۳ گره آموزش ببیند و با ۱۰ گره اجرا شود، ابعاد مشاهده عوض می‌شود و مدل لودشده سازگار نیست. در ارائه همان تنظیمات آموزش را نگه دارید.

پرسش: تفاوت پیش‌فرض کد و آزمایش رسمی را چطور توضیح می‌دهید؟

پاسخ: پیش‌فرض مهندسی برای داشبورد ۱۰ گره و ۲۰۰ گام است. آزمایش علمی گزارش برای شفافیت همگرایی ۳ گره، افق ۵۰ و ۶۰۰۰ گام آموزش است. اعداد پوستر فقط از آزمایش رسمی‌اند.

پرسش: آیا معماری قابل گسترش است؟

پاسخ: بله. زمان‌بند جدید یعنی سیاست جدید؛ معیار جدید در analytics اضافه می‌شود؛ عوض کردن DQN با PPO عمدتاً به فضای عمل و مربی محدود است. شبیه‌ساز مستقل از الگوریتم یادگیری است.

فصل ۵. شبیه‌ساز شبکه

قلب پروژه کلاس **Simulator** در فایل **app/simulation/simulator.py** است. این کلاس گره‌ها را در ناحیه تصادفی می‌چیند، در هر گام عمل‌ها را اعمال می‌کند، سن اطلاعات را به‌روز می‌کند و تاریخچه می‌سازد.

۵-۱ موجودیت‌ها

گره (Node)

هر گره شناسه، مختصات **(x, y)**، انرژی باقی‌مانده، حالت، شمارنده بسته و **Aol** دارد. سه حالت وجود دارد: **active**، **sleep**، **dead**. گره وقتی می‌میرد که انرژی‌اش صفر یا منفی شود. نسبت انرژی باقی‌مانده برای مشاهده عامل استفاده می‌شود.

عملیات اصلی گره:

- **sense()**: پرداخت هزینه حس کردن، فقط در حالت فعال
- **create_packet()**: ساخت بسته با شناسه افزایشی و مهر زمانی گام
- **send_packet()**: محاسبه فاصله تا دروازه، پرداخت انرژی ارسال، آزمایش کانال
- **wake_up() / sleep()**: ورود و خروج از خواب

بسته (Packet)

بسته واحد داده است: شناسه، گره مبدأ، اندازه ۳۲ بایت، گام ساخت، بار ساختگی و پرچم تحویل. بار معنایی در تصمیم‌گیری نقش ندارد؛ وجود بسته برای شمارش سرویس کافی است.

دروازه (Gateway)

دروازه در **(50, 50)** ثابت است، انرژی مصرف نمی‌کند و فقط بسته‌های موفق را در یک فهرست نگه می‌دارد. تابع **total_received()** تعداد کل دریافت‌هاست و وارد مشاهده و پاداش می‌شود.

زمان‌بند (Scheduler)

زمان‌بند سیاست غیربادگیر است. کلاس پایه در هر گام برای همه گره‌های زنده **transmit** می‌دهد (خطاپایه ارسال دائمی). کلاس **AlwaysSleepScheduler** همیشه **sleep** می‌دهد. عامل **DQN** این لایه را دور می‌زند و دیکشنری عمل را مستقیماً به **simulator.step** می‌دهد.

۲-۵ یک گام شبیه‌سازی، دقیق برای پای تخته

تابع **Simulator.step** این ترتیب را اجرا می‌کند:

1. اگر هیچ گره زنده‌ای نماند، **None** برمی‌گردد و اپیزود تمام می‌شود.
2. اگر عمل‌ها داده نشده باشند، زمان‌بند تصمیم می‌گیرد.
3. برای هر گره زنده: اگر ارسال بود، بیداری در صورت نیاز، حس کردن، ساخت بسته، ارسال؛ اگر خواب بود، هزینه خواب.
4. شناسه گره‌هایی که تحویل موفق داشتند جمع می‌شود.
5. **Aol** گره‌های تحویل‌شده ۱ می‌شود و بقیه یک واحد بالا می‌رود.
6. تصویر لحظه‌ای شامل گام، تعداد زنده، انرژی کل، بسته ارسالی/دریافتی/افت، میانگین **Aol** و عمل‌ها ذخیره می‌شود.
7. شمارنده گام یکی زیاد می‌شود.

ترتیب مهم است: اول عمل و کانال، بعد به‌روزرسانی **Aol**، بعد تصویر لحظه‌ای. پاداش یادگیری از تفاضل دو تصویر متوالی ساخته می‌شود.

۳-۵ تصویر لحظه‌ای و خلاصه اجرا

تاریخچه لیستی از دیکشنری‌هاست که داشبورد و معیارها از آن تغذیه می‌شوند. تابع **summary()** در پایان اجرا این‌ها را برمی‌گرداند: تعداد گام، زنده/مرده، انرژی کل، بسته ارسالی و دریافتی، افت، نسبت تحویل و میانگین **Aol**. نسبت تحویل بسته چنین تعریف می‌شود:

$$PDR = N_{received} / N_{sent} \quad (\text{اگر هیچ ارسالی نباشد، صفر})$$

۴-۵ پرسش‌های محتمل این فصل

پرسش: شبیه‌سازی پیوسته است یا گسسته؟

پاسخ: گسسته‌زمان است. هر **step** یک واحد زمان منطقی است، نه ثانیه فیزیکی شبیه‌سازی‌شده با ساعت واقعی.

پرسش: تداخل بین گره‌هایی که هم‌زمان ارسال می‌کنند مدل شده؟

پاسخ: خیر. هر ارسال جداگانه با احتمال وابسته به فاصله خودش آزمایش می‌شود. تداخل چنددسترسی عمداً در محدوده نیست.

پرسش: چرا دروازه انرژی مصرف نمی‌کند؟

پاسخ: فرض شده دروازه به برق شبکه وصل است و گلوگاه باتری گره‌های حسگر است. این فرض در کاربرد پایش محیطی رایج است.

پرسش: مکان گره‌ها هر اپیزود عوض می‌شود؟

پاسخ: با یک بذر ثابت، چیدمان تکرارپذیر است. در ارزیابی چنداپیزودی، بذر اپیزودها عوض می‌شود تا میانگین روی چند تحقق تصادفی گرفته شود.

پرسش: اگر حس کردن انرژی را تمام کند، بسته ساخته می‌شود؟

پاسخ: خیر. اگر sense شکست بخورد، ارسال آن گام انجام نمی‌شود. مرگ می‌تواند وسط عمل هم رخ دهد.

پرسش: صف یا بازارسال وجود دارد؟

پاسخ: خیر. بسته ناموفق دور ریخته می‌شود و در گام بعد در صورت انتخاب ارسال، بسته جدیدی ساخته می‌شود. این ساده‌سازی را باید صادقانه گفت.

پرسش: Scheduler هنوز لازم است اگر DQN خودش تصمیم می‌گیرد؟

پاسخ: بله، برای خطاپایه‌ها و اجرای بدون عامل. جدا بودن زمان‌بند از شبیه‌ساز یعنی می‌توان سیاست جدید قاعده‌محور اضافه کرد بدون دست زدن به فیزیک شبکه.

فصل ۶. مدل انرژی، کانال و سن اطلاعات

۶-۱ انرژی فاصله آگاه

کلاس **EnergyModel** فقط چهار هزینه را برمی‌گرداند. تنها هزینه وابسته به مکان، ارسال است. فاصله اقلیدسی بین گره و دروازه با **math.hypot** حساب می‌شود.

$$d = \sqrt{[(x_g - x_i)^2 + (y_g - y_i)^2]}$$

با **w = 0.5** رشد هزینه ملایم است نه انفجاری؛ هدف این است که گره دور‌تر باشد، اما شبیه‌سازی با انرژی ۱ ژول در چند ده گام قابل مشاهده بماند.

تفسیر	p(d)	E_tx (J)	d (m)
کنار دروازه؛ تقریباً بدون افت	1.00	0.050	0
نزدیک؛ ارسال نسبتاً ارزان و مطمئن	0.825	0.056	25
فاصله مرجع	0.650	0.075	50
نزدیک گوشه مربع؛ گران‌تر و پرریسک‌تر	0.505	0.100	70.7

حداکثر فاصله در مربع ۱۰۰×۱۰۰ از مرکز تا گوشه حدود ۷۰٫۷ متر است. پس هزینه ارسال بین حدود ۰٫۰۵ تا ۰٫۱۰ ژول می‌ماند. به علاوه ۰٫۰۱ ژول حس کردن، یک ارسال موفق یا ناموفق حدود ۰٫۰۶ تا ۰٫۱۱ ژول از باتری کم می‌کند. با باتری ۱ ژول، گره اگر همیشه ارسال کند معمولاً در کمتر از ۲۰ گام می‌میرد؛ این با طول عمر ۱۵٫۴ گام در خط‌پایه ارسال دائمی سازگار است.

۶-۲ کانال سبک

فایل **app/simulation/channel.py** سه تابع دارد: فاصله، احتمال تحویل، و آزمایش برنولی. اگر عدد تصادفی یکنواخت کوچک‌تر از **p(d)** باشد بسته می‌رسد، وگرنه **packets_dropped** یکی زیاد می‌شود.

انرژی روی تلاش مصرف می‌شود، نه روی موفقیت. این تفاوت را در ارائه برجسته کنید؛ چون توضیح می‌دهد چرا ارسال دائمی هم عمر را می‌کشد هم بخشی از انرژی را روی بسته ناموفق تلف می‌کند.

میانگین **Aol** فقط روی گره‌های زنده است. اگر همه بمیرند، میانگین صفر گزارش می‌شود تا تقسیم بر صفر رخ ندهد. این قرارداد برای سیاست‌هایی که شبکه را می‌کشند گمراه‌کننده است: عدد پایانی **Aol** ممکن است صفر دیده شود در حالی که شبکه مرده است. برای ارسال دائمی و تصادفی باید از منحنی زمانی حرف زد، نه از عدد پایانی.

$$\bar{A}(t) = (1 / |\text{Alive}(t)|) \sum_{i \in \text{Alive}(t)} A_i(t)$$

۴-۶ پرسش‌های محتمل این فصل

پرسش: این مدل همان مدل Heinzelman است؟

پاسخ: الهام‌گرفته است نه کپی. مدل کلاسیک معمولاً الکترونیک به علاوه ضریب تقویت در d به توان ۲ یا ۴ دارد. اینجا یک فرم فشرده آموزشی با وزن ۵/۰ انتخاب شده است.

پرسش: افت بسته به نویز، مانع یا تداخل وابسته است؟

پاسخ: فقط به فاصله. مدل کانال عمداً تک‌پارامتری است تا دانشجو بتواند اثر فاصله را در انرژی و PDR جدا ببیند.

پرسش: چرا احتمال را خطی کم کردید نه نمایی؟

پاسخ: خطی بودن شفاف و قابل محاسبه ذهنی است. مدل نمایی واقعی‌تر می‌تواند کار آینده باشد و در محدودیت‌ها آمده است.

پرسش: Seed کانال و مکان یکی است؟

پاسخ: شبیه‌ساز یک مولد تصادفی با همان بذر دارد که هم جای‌گذاری گره هم آزمایش کانال از آن تغذیه می‌شوند. این تکرارپذیری را ساده می‌کند.

پرسش: AOL روی گره‌های مرده چرا حساب نمی‌شود؟

پاسخ: گره مرده دیگر منبع اطلاعات نیست. اگر مرده‌ها را در میانگین بگذاریم، سن به بی‌نهایت میل می‌کند و مقایسه سیاست‌ها بی‌معنی می‌شود. البته عدد پایانی پس از مرگ کامل شبکه را باید با احتیاط خواند.

پرسش: آیا می‌توان انرژی خواب را صفر فرض کرد؟

پاسخ: از نظر مفهومی بله، ولی در سخت‌افزار واقعی خواب هم جریان نشتی دارد. مقدار 0.01% ژول این واقعیت را نمادین نگه می‌دارد و جلوی عمر بی‌نهایت در افق محدود را نمی‌گیرد.

فصل ۷. صورت‌بندی مسئله به‌صورت فرآیند تصمیم مارکوف

کلاس `IoTEnergyEnv` در `app/rl/environment.py` شبیه‌ساز را به قرارداد `Gymnasium` ترجمه می‌کند: `reset` مشاهده اولیه می‌دهد و `step` عمل را می‌گیرد و مشاهده بعد، پاداش، پایان و اطلاعات کمکی را برمی‌گرداند.

۷-۱ مشاهده

بردار مشاهده طول $2n + 3$ دارد و همه مؤلفه‌ها به بازه $[0, 1]$ نرمال شده‌اند تا برای شبکه عصبی مناسب باشند:

۱. نسبت انرژی هر گره: e_i / e_{init}

۲. پرچم زنده بودن هر گره: ۱ یا ۰

۳. زمان نرمال: t / MAX_STEPS

۴. نسبت دریافت دروازه: بسته‌های موفق تقسیم بر حداکثر ممکن $t \cdot n$

۵. میانگین `Aol` تقسیم بر `MAX_STEPS`

برای ۳ گره، مشاهده ۹ بعدی است. عامل مختصات مکانی، فاصله خام، یا نقشه کانال را مستقیم نمی‌بیند. اثر فاصله به‌صورت غیرمستقیم در تخلیه انرژی و افت بسته ظاهر می‌شود.

$$o = [e_1, \dots, e_n, a_1, \dots, a_n, \bar{t}, \rho_{rx}, \bar{A}_{norm}]$$

۷-۲ عمل

برای $n \leq 10$ فضای عمل `Discrete(2^n)` است. عدد صحیح به بیت‌ها شکسته می‌شود؛ بیت `i` عمل گره `i` است: ۱ یعنی ارسال، ۰ یعنی خواب. برای ۳ گره فقط ۸ عمل وجود دارد:

کد	بیت‌ها	معنی تقریبی
0	000	همه خواب
1	100	فقط گره ۱ ارسال
7	111	همه ارسال

اگر $n > 10$ شود، محیط به **MultiDiscrete** می‌رود که **DQN** کلاسیک آن را پشتیبانی نمی‌کند. داشبورد عمداً لغزنده را در ۱۰ قفل کرده است. با ۱۰ گره ۱۰۲۴ عمل دارید؛ بودجه آموزشی کوتاه معمولاً برای این فضا کم است.

۷-۳ پاداش

تابع **compute_reward** در **app/rl/reward.py** پاداش را از تفاضل دو تصویر لحظه‌ای می‌سازد. هدف تشویق تحویل بسته و زنده ماندن، و جریمه مصرف انرژی، مرگ گره، کهنگی و افت بسته است:

$$r = 1.0 \Delta P + 0.2 \alpha + 0.2 \eta - 0.5 \Delta E - 1.0 \Delta D - 0.15 \bar{A}_{\text{norm}} - 0.2 \Delta L$$

نماد	معنی	اثر
ΔP	بسته‌های موفق جدید در این گام	پاداش اصلی سرویس
α	نسبت گره‌های زنده	تشویق بقای شبکه
η	نسبت انرژی کل باقی‌مانده	تشویق ذخیره‌سازی
ΔE	انرژی مصرف‌شده همین گام	جریمه اسراف
ΔD	تعداد گره‌هایی که همین گام مردند	جریمه سنگین مرگ
$\bar{A}_{\text{norm}}$	میانگین سن نرمال‌شده	جریمه کهنگی
ΔL	بسته‌های افت‌شده جدید	جریمه ارسال ناموفق

وزن‌ها دستی و ابتکاری‌اند (heuristic). بهینه‌سازی وزن پاداش یا روش چندهدفه واقعی انجام نشده و این یک محدودیت صریح است. اگر وزن مرگ را خیلی زیاد کنید عامل ممکن است بیشتر بخوابد؛ اگر وزن بسته را خیلی زیاد کنید به ارسال دائمی نزدیک می‌شود.

۷-۴ پایان اپیزود

دو نوع پایان از قرارداد **Gymnasium** پیروی می‌کند:

- terminated**: هیچ گره زنده‌ای نمانده (پایان طبیعی مسئله).
- truncated**: به **MAX_STEPS** رسیده‌ایم (قطع افق زمانی).

این تفکیک مهم است چون در یادگیری تقویتی مدرن، قطع افق نباید مثل مرگ طبیعی بوت استرپ شود. کتابخانه این قرارداد را رعایت می‌کند.

۷-۵ پرسش‌های محتمل این فصل

پرسش: چرا مختصات گره در مشاهده نیست؟

پاسخ: برای کوچک ماندن مشاهده و اجبار عامل به یادگیری از اثر انرژی و افت. این یک محدودیت است: عامل موقعیت را صریح نمی‌داند. افزودن فاصله نرمال کار آینده منطقی است.

پرسش: مشاهده جزئی است یا کامل؟

پاسخ: تقریباً جزئی است چون مکان، صف و تحقق بعدی کانال دیده نمی‌شود. با این حال انرژی و حیات و AOI بخش بزرگی از حالت داخلی را پوشش می‌دهند.

پرسش: چرا عمل را فشرده کردید نه MultiDiscrete از ابتدا؟

پاسخ: DQN در Stable-Baselines3 فضای Discrete می‌خواهد. فشرده‌سازی بیت‌ماسک راه استاندارد تبدیل تصمیم چنددودویی به یک عدد است.

پرسش: انفجار فضای عمل را چطور جمع می‌کنید؟

پاسخ: با $n=3$ فقط ۸ عمل است و یادگیری معنی‌دار است. با $n=10$ فضا 10^{24} تایی است و بودجه کوتاه کافی نیست. برای شبکه بزرگ باید عامل غیرمتمرکز یا PPO چندگانه استفاده شود.

پرسش: پاداش را از کجا آوردید؟ از مقاله؟

پاسخ: خیر، طراحی مسئله‌محور است. هر جمله پاداش با یک هدف مهندسی متناظر است. اعتبارسنجی آن تجربی است: آیا DQN از خط‌پایه‌ها بهتر مصالحه می‌کند؟

پرسش: مقیاس پاداش‌ها همخوان است؟

پاسخ: تقریباً. ΔP معمولاً ۰ تا n است، ΔE کسری از ژول، مرگ ۰ و ۱. وزن ۰/۵ روی انرژی و ۱ روی مرگ یعنی مرگ تقریباً معادل از دست دادن یک بسته خیلی مهم است. ادعا نمی‌کنیم این وزن بهینه جهانی است.

پرسش: اگر Always Sleep پاداش بهتری از DQN بگیرد چه؟

پاسخ: یعنی وزن سرویس نسبت به بقای انرژی ضعیف است یا عامل خوب یاد نگرفته. در آزمایش رسمی این اتفاق نیفتاده چون خواب دائمی ΔP صفر دارد و از پاداش بسته محروم است.

فصل ۸. عامل DQN، ابرپارامترها و حلقه آموزش

۸-۱ پوشش نازک روی Stable-Baselines3

کلاس **DQNAgent** در `app/rl/dqn_agent.py` یک پوشش نازک است: ساخت مدل، یادگیری، پیش‌بینی حریصانه، ذخیره و بارگذاری. سیاست **MlpPolicy** یعنی دو لایه تمام‌متصل پیش‌فرض کتابخانه روی بردار مشاهده. اگر فضای عمل گسسته نباشد، سازنده خطا می‌دهد تا اشتباه ۱۰ گره به‌بالا خاموش نماند.

۸-۲ ابرپارامترها

پارامتر	مقدار	معنی عملی
نرخ یادگیری	0.001	گام به‌روزرسانی Adam
gamma	0.95	اهمیت آینده
حجم بافر	50,000	حافظه بازپخش
learning_starts	1,000	قبل از یادگیری فقط تجربه جمع می‌شود
batch_size	64	اندازه دسته گرادیان
train_freq	4	هر ۴ گام محیطی یک به‌روزرسانی
target_update_interval	500	تواتر به‌روزرسانی شبکه هدف
tau	1.0	جایگزینی سخت شبکه هدف، نه میانگین نرم
exploration_fraction	0.3	۳۰٪ اول بودجه برای کاهش ϵ
exploration_final_eps	0.05	کف اکتشاف

در آزمایش رسمی بودجه آموزش ۶۰۰۰ گام محیطی است. چون **learning_starts = 1000** است، تقریباً هزار گام اول فقط پر کردن بافر است و یادگیری واقعی بعد از آن شروع می‌شود. با افق ۵۰ گام، ۶۰۰۰ گام حدود ۱۲۰ اپیزود آموزشی است؛ برای فضای ۸ عملی عدد معقولی است، برای فضای ۱۰۲۴ عملی کم است.

تابع `train_dqn` محیط را می‌سازد، عامل را آموزش می‌دهد، مدل را در `experiments/models/dqn_iot_energy` ذخیره می‌کند، سپس چند اپیزود حریصانه ارزیابی می‌کند. پیش‌بینی در ارزیابی و داشبورد `deterministic=True` است تا ϵ وارد مقایسه نشود.

$$a_t = \operatorname{argmax}_a Q(s_t, a; \theta)$$
 در حالت ارزیابی حریصانه

۸-۴ پایداری و تکرارپذیری

بذر در سازنده **DQN** و محیط گذاشته می‌شود. با این حال **PyTorch** روی سخت‌افزارهای مختلف ممکن است اختلاف عددی کوچک بسازد. اعداد پوستر از یک اجرای ثبت‌شده با بذر ۴۲ هستند. اگر دوباره آموزش دهید، جدول باید از نظر کیفی شبیه باشد نه لزوماً رقم‌به‌رقم.

۸-۵ پرسش‌های محتمل این فصل

پرسش: چرا DQN نه PPO؟

پاسخ: عمل گسسته و در آزمایش رسمی بسیار کوچک است. DQN انتخاب استاندارد این فضا است. PPO برای فضای بزرگ‌تر یا سیاست احتمالی مناسب‌تر است و در کارهای آینده آمده.

پرسش: چرا از Double DQN یا Rainbow استفاده نکردید؟

پاسخ: هدف پروژه صورت‌بندی مسئله IoT است نه مسابقه الگوریتم. DQN پایه کافی است تا نشان دهیم یادگیری از خط‌پایه بهتر مصالحه می‌کند. نسخه‌های پیشرفته توسعه طبیعی کارند.

پرسش: شبکه چند لایه و چند نرون دارد؟

پاسخ: MlpPolicy پیش‌فرض Stable-Baselines3 معمولاً دو لایه ۶۴ تایی است. معماری اختصاصی طراحی نشده چون مشاهده کم بعد است.

پرسش: ۶۰۰۰ گام کم نیست؟

پاسخ: برای ۳ گره خیر؛ برای ۱۰ گره بله. این را باید قبل از استاد بگویید تا اگر داشبورد با ۱۰ گره ضعیف شد غافلگیر نشوید.

پرسش: Overfitting به یک چیدمان گره رخ نمی‌دهد؟

پاسخ: آموزش با بذر ثابت مکان‌ها را تکرار می‌کند، اما ارزیابی چند اپیزودی بذر را جابه‌جا می‌کند. با این حال تعمیم به چیدمان کاملاً جدید و تعداد گره جدید ادعا نشده است.

پرسش: مدل ذخیره‌شده چه فایلی است؟

پاسخ: فایل zip حاوی وزن شبکه و پارامترهای SB3. داشبورد اگر عامل در حافظه جلسه نباشد همین فایل را بار می‌کند.

پرسش: Learning rate را چطور انتخاب کردید؟

پاسخ: مقدار پیش‌فرض رایج 10^{-4} است. جست‌وجوی شبکه‌ای گسترده انجام نشده. اگر آموزش واگرا شود اولین کاندید کاهش نرخ یادگیری است.

فصل ۹. معیارهای ارزیابی، خطاپایه‌ها و مقایسه سیاست‌ها

۹-۱ معیارها

تابع `metrics_from_history` از تاریخچه و خلاصه یک دیکشنری تخت می‌سازد. تعریفها را حفظ باشید:

- **طول عمر:** تعداد گام‌هایی که دست‌کم یک گره زنده بوده است.
- **بسته ارسالی / دریافتی / اُفت‌شده:** شمارنده‌های تجمعی.
- **نسبت تحویل (PDR):** دریافتی تقسیم بر ارسالی.
- **میانگین Aol:** مقدار پایانی میانگین روی زنده‌ها؛ برای تفسیر بهتر از منحنی زمانی استفاده شود.
- **انرژی مصرف‌شده:** انرژی اولیه کل منهای باقی‌مانده.
- **بهره‌وری انرژی:** بسته موفق تقسیم بر ژول مصرف‌شده.

$$EE = N_{\text{received}} / (n \cdot E_{\text{init}} - E_{\text{left}})$$

۹-۲ سه خطاپایه و دلیل وجودشان

سیاست	رفتار	چه چیزی را نشان می‌دهد
ارسال دائمی	همه زنده‌ها همیشه ارسال	حداکثر فشار سرویس؛ عمر کوتاه
خواب دائمی	همه همیشه خواب	حداکثر بقا؛ سرویس صفر
تصادفی	نمونه از فضای عمل	آیا یادگیری از شانس بهتر است؟

بدون این سه خطاپایه، عدد **DQN** تفسیر ندارد. ارسال دائمی سقف مصرف و کف عمر را نشان می‌دهد. خواب دائمی سقف عمر و کف سرویس را نشان می‌دهد. تصادفی می‌گوید بهبود حاصل یادگیری است نه صرفاً وجود دو عمل.

۹-۳ پروتکل مقایسه

تابع `compare_policies` هر سیاست را چند اپیزود اجرا می‌کند (در آزمایش رسمی ۵، در داشبورد ۳) و میانگین معیارها را گزارش می‌کند. **DQN** فقط وقتی وارد جدول می‌شود که عامل آموزش‌دیده موجود باشد. بذر اپیزودها با

افست جدا می‌شود تا سیاست‌ها روی تحقق‌های تصادفی مشابه ولی نه لزوماً یکسان مقایسه شوند.

در ارزیابی DQN از seed+50 استفاده شده تا چیدمان ارزیابی عین چیدمان آموزش نباشد. این جزئیات را اگر استاد دقیق پرسید بگویید.

۹-۴ پرسش‌های محتمل این فصل

پرسش: چرا خط‌پایه هوشمند قاعده‌ای مثل آستانه انرژی نگذاشتید؟

پاسخ: می‌توانست اضافه شود و کار آینده خوبی است. سه خط‌پایه فعلی کران‌های تفسیری مسئله را می‌سازند. نبود آستانه را به‌عنوان محدودیت بپذیرید نه پنهان کنید.

پرسش: ۵ اپیزود برای آزمون آماری کم نیست؟

پاسخ: کم است. انحراف معیار گسترده گزارش نشده. ادعا «در این تنظیمات میانگین بهتر است» است نه معناداری آماری سخت. این را خودتان بگویید.

پرسش: PDR بالاتر همیشه بهتر است؟

پاسخ: نه لزوماً. اگر خیلی کم ارسال کنیم و فقط گره نزدیک بفرستد، PDR بالا و سرویس کم می‌شود. باید با تعداد بسته و عمر با هم خوانده شود.

پرسش: بهره‌وری انرژی را چرا در پوستر برجسته نکردید؟

پاسخ: چون جهش اصلی طول عمر است. بهره‌وری DQN حدود ۹/۸۹ بسته بر ژول در برابر ۸/۸۷ ارسال دائمی است؛ بهبود هست ولی داستان اصلی بقا همراه سرویس است.

پرسش: Always Sleep را می‌توان حذف کرد چون بدیهی است؟

پاسخ: نباید حذف شود. کران بالای عمر و کران پایین سرویس است و نشان می‌دهد بهینه‌سازی انرژی بدون قید سرویس بی‌معنی است.

فصل ۱۰. داشبورد، نوت‌بوک‌ها و آزمون دود

۱۰-۱ داشبورد Streamlit

نقطه ورود `streamlit run main.py` است. نوار کناری تعداد گره، افق، انرژی اولیه، بذر، هزینه‌ها، سیاست اجرا، و بودجه آموزش را می‌گیرد. سه دکمه اصلی:

- **Run Simulation**: یک سیاست را یک‌بار اجرا می‌کند و نمودار انرژی، زنده، بسته، **Aol**، نقشه و جدول گره را نشان می‌دهد.
 - **Train DQN**: آموزش می‌دهد، مدل را ذخیره می‌کند و پاداش ارزیابی را نشان می‌دهد.
 - **Compare Policies**: جدول چنداپیزودی می‌سازد. اگر عامل نباشد فقط خط‌پایه‌ها می‌آیند.
- نقشه شبکه با **Altair** گره‌ها و دروازه را روی صفحه **X-Y** نشان می‌دهد. رنگ نقطه حالت گره را مشخص می‌کند. این همان تصویری است که در ارائه زنده باید روی آن انگشت بگذارید.

رابط انگلیسی است. روی دکمه‌ها فارسی توضیح دهید. لغزنده آموزش پیش‌فرض داشبورد ممکن است ۳۰۰۰ باشد؛ برای نزدیک شدن به گزارش آن را ۶۰۰۰ کنید و تعداد گره را ۳ بگذارید.

۱۰-۲ نوت‌بوک‌های آزمایشی

نوت‌بوک	هدف آموزشی
01_node_simulation.ipynb	گره و انرژی
02_simulation_core.ipynb	شبیه‌ساز و خط‌پایه‌ها
03_packet_generation.ipynb	بسته و دروازه
04_rl_environment_testing.ipynb	محیط Gymnasium
05_dqn_training.ipynb	آموزش عامل
06_results_analysis.ipynb	جدول و نمودار مقایسه

نوت‌بوک‌ها مسیر یادگیری خودتان هستند، نه هسته محصول. در ارائه لازم نیست باز شوند مگر استاد مسیر توسعه را بپرسد.

فایل `tests/test_smoke.py` با `unittest` این‌ها را در شبکه ۳ گره و افق ۲۰ گام چک می‌کند:

- ساخت گره، بسته، تحویل قطعی به دروازه
- ارسال دائمی بسته می‌سازد؛ خواب دائمی بسته صفر و انرژی بیشتر دارد
- یک اپیزود تصادفی محیط بدون خطا تمام می‌شود و ابعاد مشاهده درست است
- آموزش خیلی کوتاه **DQN**، ذخیره، بارگذاری، و حضور **dqn** در جدول مقایسه
- کمک‌تابع‌های داشبورد برای سه سیاست و **DQN**

```
python tests/test_smoke.py
```

این آزمون واحد جزئی برای هر فرمول نیست؛ ضمانت می‌کند حلقه کامل از شبیه‌ساز تا آموزش کوتاه نشکند. زمان اجرا معمولاً چند ثانیه تا حدود یک دقیقه است چون دو بار آموزش خیلی کوتاه انجام می‌شود.

۴-۱۰ پرسش‌های محتمل این فصل

پرسش: چرا تست واحد برای تک‌تک فرمول‌ها ننوشتید؟

پاسخ: پروژه کارشناسی با آزمون دود انتهابه‌انتها پوشش داده شده است. تست واحد برای انرژی و کانال می‌توانست قوی‌تر باشد و به‌عنوان کار آینده قابل ذکر است.

پرسش: داشبورد پژوهشی است یا دمو؟

پاسخ: هر دو. همان توابع ارزیابی پژوهش را صدا می‌زند؛ فقط پوسته تعاملی دارد. اعداد علمی باید از تنظیمات کنترل‌شده بیایند نه از هر لغزنده تصادفی.

پرسش: چرا رابط فارسی نشد؟

پاسخ: کتابخانه‌ها و شناسه‌های سیاست انگلیسی‌اند. برای ارائه، توضیح شفاهی فارسی روی کنترل انگلیسی کافی و شفاف است.

پرسش: اگر مدل از قبل نباشد Compare چه می‌کند؟

پاسخ: فقط سه خط‌پایه را مقایسه می‌کند و پیام می‌دهد DQN آموزش داده نشده است. این رفتار عمدی است تا جدول خالی یا خطا ندهد.

فصل ۱۱. نتایج آزمایش رسمی و تفسیر نمودارها

۱۱-۱ پروتکل آزمایش

اعدادی که باید حفظ باشید فقط از این تنظیمات می‌آیند:


مورد	مقدار
تعداد گره	3
افق	50
انرژی اولیه هر گره	1.0 J
گام آموزش	6000
تعداد اپیزود ارزیابی	5
بذر	42
LOSS_FACTOR	0.35
کف تحویل	0.45

۱۱-۲ جدول نتایج

سیاست	Lifetime	Sent	Received	Dropped	PDR	AoI	E_left	EE
ارسال دائمی	15.4	37.8	26.6	11.2	0.70	—	0.00	8.87
خواب دائمی	50.0	0.0	0.0	0.0	0.00	50.0	2.85	0.00
تصادفی	33.0	37.4	26.2	11.2	0.70	—	0.00	8.73
DQN	49.4	38.8	29.4	9.4	0.76	16.2	0.03	9.89


ستون AoI برای ارسال دائمی و تصادفی در جدول رسمی با خط تیره آمده چون همه گره‌ها در پایان مرده‌اند و میانگین روی زنده تهی گمراه‌کننده است. از روی منحنی زمانی صحبت کنید.

Policy comparison




شکل ۱-۱. مقایسه چهار معیار کلیدی بین سیاست‌ها.


Total energy over time




شکل ۱-۲. انرژی کل شبکه در زمان. ارسال دائمی حدود ۱۵ می‌میرد؛ تصادفی حدود ۳۳؛ DQN تا نزدیک ۵۰ جیره‌بندی می‌کند.



شکل ۱۱-۳. میانگین AoI. خواب دائمی خط راست با شیب ۱ است. DQN سن را گاهی بالا می‌برد و با ارسال ریست می‌کند.



شکل ۱۱-۴. انباشت بسته‌های دریافتی در زمان.



شکل ۱۱-۵. نسبت تحویل بسته.

۳-۱۱ تفسیر، نه فقط عدد

ارسال دائمی تا وقتی زنده است خوب سرویس می‌دهد، ولی شبکه را در حدود گام ۱۵ می‌کشد و حدود ۱۱ بسته را هم روی کانال تلف می‌کند. خواب دائمی هر سه گره را تا گام ۵۰ زنده نگه می‌دارد و ۲/۸۵ ژول از ۳ ژول را نگه می‌دارد، اما سرویس صفر و **Aol** برابر ۵۰ یعنی اطلاعات کاملاً کهنه است. تصادفی وسط این دو است: عمر ۳۳ گام، سرویس نزدیک ارسال دائمی، بدون یادگیری ساختار فاصله.

DQN تقریباً تا انتهای افق زنده می‌ماند (۴۹/۴ از ۵۰)، بسته موفق بیشتری از ارسال دائمی می‌رساند (۲۹/۴ در برابر ۲۶/۶)، افت را کم می‌کند (۹/۴ در برابر ۱۱/۲) و **PDR** را به حدود ۰/۷۶ می‌برد. این یعنی عامل یاد گرفته همه انرژی را در ابتدای اپیزود نسوزاند و احتمالاً ارسال‌های کم‌بازده را کمتر انتخاب کند. انرژی باقی‌مانده نزدیک صفر است؛ پس سیاست خسیس مطلق نیست، بلکه انرژی را تا آخر افق خرج سرویس می‌کند. میانگین **Aol** برابر ۱۶/۲ نشان می‌دهد تازگی فدای بقا نشده است؛ برخلاف خواب دائمی که سن تا ۵۰ بالا می‌رود.

پاداش اپیزود میانگین حدود ۲۹/۸ برای **DQN** در برابر حدود ۲۷/۰ تصادفی است. این همسو با معیارهای مهندسی است، ولی معیار اصلی ارائه باید طول عمر، بسته و **PDR** باشد نه خود پاداش؛ چون پاداش تابع طراحی ماست.

جمله یک خطی تفسیر جدول

ارسال دائمی سرویس می‌دهد و زود می‌میرد؛ خواب دائمی زنده می‌ماند و سرویس صفر است؛ DQN تقریباً تا آخر زنده می‌ماند و از ارسال دائمی هم بسته موفق بیشتری می‌رساند.

۴-۱۱ آنچه نتایج ادعا نمی‌کنند

- تعمیم به ۱۰ گره، افق ۲۰۰، یا سخت‌افزار واقعی.
- برتری آماری با آزمون فرض.
- بهینه‌بودن وزن پاداش.
- شکست دادن مقالات مسیریابی روی بنچمارک آن‌ها.

۵-۱۱ پرسش‌های محتمل این فصل

پرسش: چرا DQN بسته بیشتری از Always Transmit دارد با اینکه کمتر همیشه ارسال می‌کند؟

پاسخ: چون عمرش طولانی‌تر است و افت کمتری دارد. Always Transmit زود می‌میرد و بخشی از تلاش‌ها روی فاصله بد تلف می‌شود. DQN در گام‌های بیشتر، ارسال‌های به‌صرفه‌تری انجام می‌دهد.

پرسش: آیا ممکن است این نتیجه شانس باشد؟

پاسخ: میانگین ۵ اپیزود است و واریانس کامل گزارش نشده. الگوی کیفی (عمر نزدیک خواب، سرویس بهتر از ارسال دائمی) با منطق پاداش سازگار است، اما ادعای آماری سخت نمی‌کنیم.

پرسش: اگر با ۱۰ گره اجرا کنیم و DQN بدتر از Random شد؟

پاسخ: فضای عمل ۱۰۲۴ تایی با آموزش کوتاه همگرا نمی‌شود. این شکست الگوریتم به‌صورت مطلق نیست؛ شکست بودجه یادگیری در فضای بزرگ است. اعداد رسمی ۳ گره معتبرند.

پرسش: چرا انرژی باقی‌مانده DQN تقریباً صفر است؟ خوب است یا بد؟

پاسخ: در افق محدود، خرج کردن انرژی تا آخر اگر سرویس بسازد منطقی است. خسیس بودن وقتی خوب است که افق نامعلوم یا تعویض باتری غیرممکن‌تر باشد. اینجا افق ۵۰ مشخص است.

پرسش: PDR برابر ۰/۷۶ از نظر مهندسی شبکه خوب است؟

پاسخ: برای کانال آموزشی با کف ۰/۴۵ عدد معقولی است. در شبکه واقعی به لایه MAC، کدگذاری و بازارسال هم بستگی دارد. اینجا فقط مقایسه نسبی بین سیاست‌ها معنی دارد.

پرسش: منحنی انرژی DQN چرا دیرتر پایین می‌آید؟

پاسخ: چون گاه‌گاهی خواب را انتخاب می‌کند. شیب ملایم‌تر یعنی نرخ مصرف کمتر در واحد زمان و در نتیجه رسیدن به انتهای افق.

پرسش: Always Sleep چرا ۲/۸۵ ژول باقی می‌گذارد نه ۳؟

پاسخ: هر گام ۰/۰۰۱ ژول خواب برای هر گره. سه گره در ۵۰ گام یعنی ۰/۱۵ ژول مصرف و ۲/۸۵ باقی. این را می‌توانید پای تخته حساب کنید.

پرسش: نتیجه را چطور به یک کاربرد واقعی وصل می‌کنید؟

پاسخ: در پایش محیطی با حسگر باتری محدود، سیاست یادگرفته شده می‌تواند به جای ارسال پیوسته، ارسال را جیره‌بندی کند تا فصل پایش تمام شود و داده همچنان برسد. انتقال به سخت‌افزار نیازمند مدل کانال واقعی است.

فصل ۱۲. محدودیت‌ها، کارهای آینده و جمع‌بندی

۱۲-۱ محدودیت‌ها – با افتخار و دقیق

1. شبیه‌سازی نرم‌افزاری بدون حلقه سخت‌افزار.
2. توپولوژی ستاره‌ای تک‌گام؛ بدون مسیریابی، خوشه‌بندی و چندروازه.
3. مدل کانال و انرژی آموزشی؛ بدون تداخل، محوشدگی چندمسیره و لایه **MAC**.
4. انفجار فضای عمل با رشد n ؛ سقف عملی ۱۰ و آزمایش علمی ۳ گره.
5. مشاهده بدون مختصات و کیفیت کانال صریح.
6. وزن پاداش دستی؛ بدون جست‌وجوی چندهدفه.
7. تعداد اپیزود ارزیابی کم؛ بدون فاصله اطمینان.
8. بدون صف و بازاریار؛ بسته ناموفق از بین می‌رود.
9. داده حسگر مصنوعی.

۱۲-۲ کارهای آینده

- الگوریتم **PPO** یا **Double DQN** و مقایسه الگوریتمی داخل همین محیط.
- عامل چندگانه: هر گره شبکه خودش را دارد تا n بزرگ مقیاس‌پذیر شود.
- افزودن فاصله، مکان یا تخمین $p(d)$ به مشاهده.
- خط‌پایه قاعده‌ای: ارسال اگر انرژی و **Aol** از آستانه گذشت.
- مدل کانال واقعی‌تر و تداخل هم‌زمان.
- آزمایش روی سخت‌افزار ارزان مثل **ESP32** با دروازه **MQTT**.
- گزارش واریانس و آزمون آماری روی بذره‌های بیشتر.

۱۲-۳ جمع‌بندی

این پروژه یک حلقه کامل از مسئله مهندسی تا سیاست یادگرفته‌شده ساخت: شبیه‌ساز فاصله‌آگاه با افت و سن اطلاعات، محیط یادگیری استاندارد، عامل **DQN**، سه خط‌پایه تفسیرپذیر، داشبورد ارائه، و آزمون دود. در تنظیمات رسمی، سیاست یادگرفته‌شده توانست عمر شبکه را نزدیک کران بالای خواب دائمی نگه دارد و هم‌زمان سرویس و

نسبت تحویل را از ارسال دائمی بهتر کند. این نتیجه در یک شبیه‌سازی کنترل‌شده معتبر است و تعمیم به دنیای فیزیکی کار بعدی است، نه ادعای فعلی.

جمله آخر ارائه: «یادگیری تقویتی عمیق در این شبیه‌سازی کنترل‌شده، مصالحه بهتری میان عمر شبکه و سرویس داده ساخت؛ آزمایش روی سخت‌افزار واقعی گام بعدی است.»

۴-۱۲ پرسش‌های محتمل این فصل

پرسش: اگر یک سال دیگر روی پروژه وقت داشتید چه می‌کردید؟

پاسخ: اول مشاهده را با فاصله غنی می‌کردم، بعد عامل غیرمتمرکز برای n بزرگ، بعد خط‌پایه آستانه‌ای، و در نهایت یک آزمایش کوچک روی چند برد حسگر واقعی.

پرسش: خطر اصلی نتیجه‌گیری شما چیست؟

پاسخ: بیش‌تعمیم. نتایج برای ۳ گره و مدل کانال ساده است. خطر این است که داشبورد با تنظیمات دیگر خلاف جدول را نشان دهد و مخاطب کل کار را رد کند.

پرسش: این کار مقاله می‌شود؟

پاسخ: به‌صورت گزارش کارشناسی و پوستر آموزشی بله. برای مقاله پژوهشی باید مقایسه الگوریتمی گسترده‌تر، واریانس، و احتمالاً سناریوی بزرگ‌تر اضافه شود.

پرسش: سهم یادگیری عمیق در برابر یک قاعده ساده چقدر است؟

پاسخ: بدون خط‌پایه آستانه‌ای نمی‌توان ادعا کرد هیچ قاعده ساده‌ای به این مصالحه نمی‌رسد. می‌توان ادعا کرد نسبت به سه کران موجود بهتر است. این صادقانه‌ترین جواب است.

پیوست آ. واژه‌نامه دو زبانه

فارسی	انگلیسی	یادداشت
اینترنت اشیا	Internet of Things (IoT)	دستگاه‌های متصل حسگر/عملگر
شبکه حسگر بی‌سیم	WSN	زمینه کلاسیک مسئله انرژی
دروازه	gateway / sink	نقطه جمع‌آوری بسته
سن اطلاعات	Age of Information	کهنگی داده در مقصد
نسبت تحویل بسته	Packet Delivery Ratio	دریافتی بر ارسالی
یادگیری تقویتی	Reinforcement Learning	یادگیری از پاداش
فرآیند تصمیم مارکوف	MDP	قالب وضعیت-عمل-پاداش
شبکه عمیق کیو	DQN	تقریب Q با شبکه عصبی
حافظه بازپخش	experience replay	بافر گذارها
شبکه هدف	target network	ثبات هدف بلمن
خط‌پایه	baseline	سیاست مرجع برای مقایسه

پیوست ب. راهنمای اجرا برای جلسه ارائه

```
python -m venv venv venv\Scripts\activate pip install -r requirements.txt streamlit  
run main.py
```

تنظیمات پیشنهادی نوار کناری برای نزدیک شدن به جدول رسمی:

- تعداد گره = ۳ (نه ۱۰)
- حداکثر گام = ۵۰ (نه ۲۰۰)
- انرژی اولیه = ۱
- بذر = ۴۲
- گام آموزش = ۶۰۰۰

1. امشب **Train DQN** را بزنید تا مدل ذخیره شود.

2. فردا **Always Transmit** را اجرا کنید و مرگ زودرس را نشان دهید.

3. **Always Sleep** را اجرا کنید و بسته صفر و **Aol** بالا را نشان دهید.

4. **DQN** را اجرا کنید و نقشه و منحنی انرژی را نشان دهید.

5. **Compare Policies** را بزنید تا جدول چهارتایی دیده شود.

اگر وایفای سالن مشکل داشت، همین PDF و نمودارهای assets/charts و پوستر docs/poster را به عنوان پشتیبان داشته باشید.

پیوست ج. برگه تقلب یک صفحه ای دفاع

عنوان: بهینه سازی انرژی IoT با DQN.

مسئله: هر گره در هر گام ارسال یا خواب.

روش: شبیه ساز فاصله آگاه + DQN + Gymnasium + سه خط پایه + داشبورد.

فرمول انرژی: $E_{tx}(d) = 0.05 \cdot [1 + 0.5 \cdot (d/50)^2]$.

فرمول کانال: $p(d) = \text{clip}(1 - 0.35 \cdot (d/50), 0.45, 1)$.

پاداش: بسته و بقا مثبت؛ مصرف، مرگ، کهنگی و افت منفی.

نتیجه: عمر ۴۹/۴، بسته ۲۹/۴، PDR برابر ۰/۷۶، Aol برابر ۱۶/۲.

فرق با مقالات: آن ها مسیریابی یا بازی صنعتی؛ این کار تصمیم خواب/ارسال تک گام و قابل نمایش.

محدودیت: تک گام، ۳ گره، کانال ساده، پاداش دستی، بدون سخت افزار.

1. Transforma Insights, "Global IoT connections will grow from 21 billion in 2025 to 48 billion in .2035," Apr. 2026. [Online]
2. M. A. Alsheikh, S. Lin, D. Niyato, and H.-P. Tan, "Machine Learning in Wireless Sensor Networks: Algorithms, Strategies, and Applications," **IEEE Communications Surveys & Tutorials**, vol. 16, no. 4, pp. 1996–2018, 2014
3. M. Mohamed, A. Ahmed, and N. Morsy, "Survey on Wireless Sensor Network Applications and Energy Efficient Routing Protocols," **Wireless Personal Communications**, vol. 101, no. 2, pp. 1019–1055, 2018
4. W. R. Heinzelman, A. Chandrakasan, and H. Balakrishnan, "Energy-Efficient Communication Protocol for Wireless Microsensor Networks," in **Proc. 33rd Hawaii International Conference on System Sciences**, 2000
5. G. Kaur and P. Chanak, "Energy-Efficient Intelligent Routing Scheme for IoT-enabled Wireless Sensor Networks," **IEEE Internet of Things Journal**, vol. 8, no. 14, pp. 11440–11449, 2021
6. X. Meng, H. Kan, and X. Xu, "Deep Reinforcement Learning-Based Topology Optimization for Self-Organized Wireless Sensor Networks," arXiv:1910.14199, 2019
7. N. Liu, J. Wang, F. Tao, Z. Fu, and B. Liu, "EDRP-GTDQN: An Adaptive Routing Protocol for Energy and Delay Optimization in Wireless Sensor Networks Using Game Theory and Deep Reinforcement Learning," **Ad Hoc Networks**, vol. 166, 2025
8. P. S. Banerjee, S. Goswami, and D. De, "NashDQNSleep: Nash-based Deep Q-Network Adaptive Sleep Scheduling for Energy Efficiency and Age of Information Optimization in Industrial Internet of Things," **Engineering Applications of Artificial Intelligence**, vol. 161, 2025
9. A. S. Leong, S. Dey, and D. E. Quevedo, "Deep Reinforcement Learning for Wireless Sensor Scheduling in Cyber-Physical Systems," arXiv:1809.05149, 2018